

基于多通道并行卷积神经网络和注意力机制的 铣削颤振在线监测方法

金一涵, 魏创, 唐钰哲, 周明东*

(上海交通大学 机械与动力工程学院 上海市复杂薄板结构数字化制造重点实验室, 上海市 200240,
Email: mdzhou@sjtu.edu.cn)

摘要: 铣削颤振是机械加工中的常见问题, 显著影响加工质量、刀具寿命和生产效率。传统的颤振监测方法通常依赖人为设定的特征参数和阈值, 这类方法容易引发特征冗余, 同时阈值设定也具有较强的主观性, 难以适应复杂多变的工况。为了解决上述问题, 迫切需要一种更加智能化、自动化的监测方法。本文提出了一种基于多通道并行卷积神经网络 (MC-CNN) 与通道自注意力机制 (ECA) 的铣削颤振在线监测方法。通过 MC-CNN 从多个传感器采集的信号中自动提取和融合多源信息特征, 减少了人工干预对特征选择的依赖, 有效应对了阈值设定中的主观性问题。引入 ECA 机制后, 模型能够动态调整特征权重, 增强了对关键特征的识别能力, 提高了颤振监测的精度和适应性。在卧式加工中心上的实验结果表明, 所提模型相较于 LSTM、Transformer 等传统模型, 具有更高的分类准确率和更短的训练时间, 展示了出色的计算效率和实时性能。此外, 该方法在不同颤振状态下均表现出较强的泛化能力, 能够稳定适应不同加工条件, 为铣削颤振监测提供了一种有效的技术手段。

关键词: 铣削颤振; 在线监测; 多通道并行; 卷积神经网络; 通道自注意力机制

中图分类号: F407.4, TP183

文献标志码: A

Online Monitoring Method for Milling Chatter Based on Multi-Channel Parallel Convolutional Neural Networks and Attention Mechanisms

JIN Yihan, WEI Chuang, TANG Yuzhe, ZHOU Mingdong*

(Shanghai Key Laboratory of Digital Manufacture for Thin-Walled Structures, School of Mechanical
Engineering, Shanghai Jiao Tong University, Shanghai 200240, China)

Abstract: Milling chatter is a common issue in machining processes that significantly impacts both the quality and efficiency of machining. The traditional approach to monitor milling chatter depends on manually set feature parameters and thresholds to identify chatter incidents, resulting in issues such as feature redundancy and the subjectivity of threshold determination. To address these issues, a novel online monitoring method for milling chatter is proposed, based on Multi-Channel Parallel Convolutional Neural Networks (MC-CNN) and self-attention mechanisms. This method leverages MC-CNN to automatically extract and integrate signal features from multiple sensors, thereby reducing human intervention. The introduction of the Channel-wise Attention Mechanism (ECA) further enhances the model's ability to identify key features by dynamically adjusting feature weights. Experimental results conducted on a horizontal machining center demonstrate that the proposed MC-CNN+ECA model significantly improves classification accuracy and reduces training time compared to traditional models such as LSTM and Transformer. This model exhibits superior classification performance and computational efficiency.

Key words: Milling chatter; Online monitoring; Convolutional Neural Networks(CNN); Multi-Channel Parallel; Efficient Channel Attention(ECA)

收稿日期: XXXX-XX-XX

基金项目: 国家攻关项目 (GG20211120401);

*: 通讯作者

铣削颤振是机械加工过程中一种常见且复杂的异常现象,主要表现为铣刀与工件之间的不规则振动。这种振动不仅会影响加工工件表面的质量,导致其粗糙度增加、精度降低,还可能引发刀具磨损加剧等一系列负面影响^[1]。因此,通过对颤振进行实时监测从而提高工件加工质量显得尤为重要。然而,颤振作为切削加工系统在非周期性外部激励力持续作用下产生的一种强烈自激振动,具有时变特性和系统结构的复杂性,难以在加工前进行准确预测^[2]。传统的工业监测方法通常在加工完成或设备停机后,通过分析振纹和工件表面质量进行离线检测,这种方法效率较低且监测结果滞后于铣削加工,无法及时反馈^[3]。深入研究刀具颤振的在线监测技术,对于保障加工质量和提高加工效率具有重要的实际意义。

铣削颤振的在线监测指通过实时采集铣削加工过程中的信号(如振动信号、声信号和切削力信号等)并将这些信号输入到在线监测系统中进行分析,实现对颤振的实时识别,并及时反馈机床系统,从而确保工件加工质量、提高加工效率。由于颤振的发生伴随能量分布的变化,即信号能量逐渐集中到特定频带^[4],传统颤振在线监测方法主要利用信号分析技术(如小波包分解^[4]),对不同频率下的信号能量进行计算,进一步提取特征参数(如能量熵^[5]、能量波峰因子^[6]和多尺度熵^[7]等),通过监测特征参数变化来判断颤振的存在。然而,传统方法依赖于人为设定的特征参数和对应的阈值来判断颤振的发生,如ZHANG等依据^[5]不同频率下信号的能量熵设定阈值来判断颤振的发生。这些阈值的确定通常需要大量重复实验,且不同机床设备、不同工况下的阈值通用性不足,限制了该方法的泛用性。

近年来,随着机器学习算法的不断发展,基于机器学习的铣削颤振在线监测方法受到了广泛关注。考虑到在铣削过程中,所得原始信号常常会受到环境噪声的干扰,且多源传感器输入的高维数据易影响模型的计算效率,而数据预处理和特征提取,不仅有助于去除噪声和降低数据维度,还能优化模型的性能和计算效率,使得预处理和特征提取成为不可或缺的环节^[8]。因此,现有基于机器学习的铣削颤振在线监测方法主要通过四个阶段实现对颤振的实时监测,包括:数据采集、数据预处理、特征提取和状态识别^[9]。在数据采集阶段,通常使用多种类型的传感器信号来监测铣削颤振,包括振动信号、力矩信号、切削力信号、电流信号和声信号等。例如,Fu等^[10]使用振动信号进行铣削颤振的实时监测;Tansel等^[11]利用主轴力矩信号监测端铣削过程;Li等^[12]通过对切削力特征的学习实现颤振监测;Lamraoui等^[13]仅通过主轴电流信号实现CNC铣削颤振的监测;Shi等^[14]则基于声信号进行高速铣削中

的颤振监测。Wang等^[9]指出,与切削力和主轴力矩信号相比,振动信号对切削过程中颤振状态的变化更为敏感。因此,本研究选择使用振动数据对铣削过程中的颤振进行在线监测。

在数据预处理和特征提取阶段,现有研究通常采用时域、频域和时频域的方法来处理信号并提取关键信息。Lei等^[15]在回转机械故障诊断的研究中使用了特征参数,该团队选择了24个时域和频域特征参数,包括平均幅值、标准差、裕度因子和脉冲因子等。在此基础上,Lamraoui等^[16]选取了时域中的方差、均方差、裕度因子和峰值值作为颤振监测的特征参数。除此之外,频域特征参数也被广泛应用于颤振监测,例如,Jia等^[17]通过快速傅里叶变换(FFT)获得加速度信号的频域曲线,并将其标准差和一步自相关函数的积分作为颤振监测的特征。Liu等^[18]提出,当铣削颤振发生时,相邻颤振频率与切削频率的差值将为定值,这一特征参数可作为判断颤振发生的依据。此外,时频特征也能有效反映颤振特征,例如Chen等^[19]通过FFT获取频域中的主频带,并利用短时傅里叶变换(STFT)生成时频图像,再通过支持向量机(SVM)进行分类识别。

然而,上述铣削颤振数据特征提取方法大多依赖于人为设定的时域、频域或时频域特征参数,这些方法会带来主观性和冗余性,导致训练得到的监测模型应用工况受限。因此,开发更加自动化和有效的特征提取方法具有重要的研究价值。正如Navarro-Devia等^[20]所指出,有效的特征参数在加工过程中可能会随加工条件的变化而发生变化。为了解决这一问题,Liu等^[21]采用了主成分分析(PCA)对人为选定的特征参数进行进一步降维,从而突出关键特征。然而,主成分分析需要针对不同工况进行单独处理,操作复杂且繁琐。为此,Fu等^[22]提出了使用深度信念网络(DBN)自动提取信号特征的方法,以克服人为选择特征的局限性,并减少对模型监测效果的依赖。尽管DBN能够自动提取特征,只能处理单一信号导致计算效率较低,当面对多通道传感器输入时,计算时间会随着数据量的增加而显著增长,从而影响颤振监测的实时性。

为解决上述问题,本文提出了一种基于多通道并行卷积神经网络和注意力机制的铣削颤振在线监测方法。该方法通过多通道并行卷积神经网络(MC-CNN)自动提取时域信号中的特征参数。通过利用卷积神经网络的局部感受和全局共享权重的特性提升模型的泛化能力;引入通道自注意力机制(ECA),动态调整特征矩阵中的权重,有效减少冗余信息的影响,增强模型对关键特征的识别能力,提高计算效率。在卧式加工中心开展铣削实验,复现了稳定加工、轻微颤振和严重颤振三种加工状态,搭建实验数

数据集,验证所提方法的有效性。相比于常用分类模型,所提方法具备更高的准确率,且需要更少的训练时间。

1 基于多通道并行卷积神经网络的特征提取算法


1.1 卷积神经网络

卷积神经网络(CNN)是一种深度学习算法,以其独特的结构设计和局部感受野、权重共享等特性广泛应用于图像识别、自然语言处理和时间序列分析等领域。CNN的核心操作是卷积,通过在整个输入数据上滑动同一个卷积核来提取每个滑动区域的局部特征。这种方法不仅减少了参数数量,还显著提升了模型的计算效率和泛化能力。假设输入数据为一个二维矩阵 I ,其大小为 $H \times W$,采用二维卷积核 K ,其大小为 $h \times w$,输出矩阵为 O ,则其卷积公式如下:

$$O(i,j) = \sum_{m=0}^{h-1} \sum_{n=0}^{w-1} I(i+m,j+n) \cdot K(m,n) \quad (1)$$

其中 $I(i+m,j+n)$ 表示输入矩阵 I 中位于 $(i+m,j+n)$ 的元素, $K(m,n)$ 表示卷积核 K 中位于 (m,n) 的元素, $O(i,j)$ 表示输出矩阵中位于 (i,j) 的元素。

在实际运行过程中,一个完整的卷积操作包含三个过程:定位卷积核、元素相乘并相加和移动卷积核。首先,根据输入数据和卷积核的尺寸在输入数据上定位卷积核的位置。其次,按照公式(1),将卷积核与输入数据的重叠区域对应的元素相乘,并将结果进行累加。最后,将卷积核按照设定的步幅在输入数据上滑动,重复上述步骤,如图1所示。



▲图1 二维矩阵卷积操作示意图

1.2 多通道并行卷积神经网络

在信号处理与模式识别领域,多源输入的时域信号处理是一个重要的研究方向。这类信号由多个传感器同步采集,包含了丰富的时空信息和跨传感器的互补性。采用多通道并行卷积神经网络(MC-CNN)处理这些信号,能够

并且独立地从每个传感器的数据中自动提取高层次的特征表示。MC-CNN不仅能够进行特征提取,还能对提取的特征进行融合和重构,从而进一步增强特征的表达能力。

在处理多通道输入数据时,MC-CNN的卷积核具有多个通道,每个通道的卷积核在对应的输入数据上独立应用。通过将不同通道的卷积结果进行叠加,MC-CNN能够融合来自多个通道的信息,形成更为全面的特征表示。这一过程加快了信号处理的速度,并有效减少了传统方法中人为设定特征参数的主观性和冗余性。

假设输入数据 I 的尺寸为 $C \times H \times W$,即 I 具有 C 个通道,每个通道的输入数据大小为 $H \times W$ 。相应的,卷积核 K 也具有 C 个通道,每个通道卷积核的大小为 $h \times w$,则输出特征图的卷积公式如下:

$$O(i,j) = \sum_{c=1}^C \sum_{m=0}^{h-1} \sum_{n=0}^{w-1} I_c(i+m,j+n) \cdot K_c(m,n) \quad (2)$$

其中 I_c 表示输入矩阵的第 c 个通道, K_c 表示卷积核的第 c 个通道, $O(i,j)$ 表示输出矩阵中位于 (i,j) 的元素。通过这种方式,MC-CNN能够在多个通道中提取特征并将其融合,生成具有更高表达能力的特征图,为后续的特征重构和进一步分析提供了丰富的基础。

1.3 特征提取算法


多通道并行卷积神经网络(MC-CNN)通过自动学习和优化网络参数,确保从数据中提取出最具代表性和区分度的特征。在网络的深层阶段,MC-CNN能够通过融合机制整合来自不同传感器通道的特征,从而实现跨传感器信息的互补与增强。这种处理方式不仅提高了模型对复杂环境变化的适应能力,还显著提升了在分类、识别等任务上的性能,为信号处理与模式识别领域的研究提供了有力支持。

本研究所提出的多源信号输入特征提取模型由两个多通道并行卷积神经网络、两个池化层和两个激活函数组成。模型的输入格式为21个通道,每个通道的信号长度为20000。模型的具体参数配置如下表所示:

▲表1 多源输入特征提取网络结构

神经网络层	输出格式	参数量
输入层	21×20000	0
卷积层1	64×4996	21568
激活函数层	64×4996	0
池化层1	64×1248	0
卷积层2	128×309	131200
激活函数层	128×309	0
池化层2	128×77	0
总参数量: 152704		

在模型的第一层，使用了多通道并行的一维卷积层，其输入通道数为 21，输出通道数为 64，卷积核尺寸为 16，步幅为 4。这一卷积层能够同时处理 21 个传感器通道的特征，并在降低输入维度的同时提取高层次的抽象特征。激活函数 1 和激活函数 2 采用了 ReLU 函数，引入非线性因素，增强了模型对复杂特征的学习能力。池化层 1 和池化层 2 使用最大池化层，卷积核尺寸为 4，步幅为 4，以减小特征矩阵的尺寸并提高计算效率。在第二层，使用了多通道并行的一维卷积层，其输入通道数为 64，输出通道数为 128，卷积核尺寸为 16，步幅为 4，进一步提取特征并降低输入维度，模型结构图如下：



▲图2 多源信号融合的特征提取模型

总体而言，本研究提出的基于 MC-CNN 的特征提取模型通过多通道并行处理、特征融合和重构，显著提升了对多源信号的处理能力。该模型使用 21 个输入通道，每个通道信号的长度为 20000，通过卷积操作将特征逐步提取和整合，最终得到尺寸为 128×77 的特征矩阵。模型中的池化层和激活函数进一步增强了对复杂特征的学习能力和计算效率。综上所述，该 MC-CNN 模型为多源信号处理提供了一种高效且精准的方法。

2 基于通道自注意力机制的铣削颤振在线监测算法

2.1 通道自注意力机制

自注意力机制是一种广泛应用于自然语言处理和计算机视觉领域的技术，其核心在于捕捉输入序列中各元素之间的关系^[23]。对于给定的输入矩阵，通用自注意力机制通过三个不同的线性变换将输入矩阵 X 分别转化为查询(Query)矩阵 Q 、键(Key)矩阵 K 和值(Value)矩阵 V ，其变换公式如下所示：

$$Q = X \cdot W_Q \quad (3)$$

$$K = X \cdot W_K \quad (4)$$

$$V = X \cdot W_V \quad (5)$$

其中 W_Q 、 W_K 和 W_V 为可学习的权重矩阵。

注意力矩阵 A 的计算公式为：

$$A = \frac{Q \cdot K^T}{\sqrt{d_K}} \quad (6)$$

其中， d_K 表示键向量的维度， $\sqrt{d_K}$ 用于对注意力矩阵进行缩放，控制其数值范围。

通过对注意力矩阵 A 进行归一化处理，可以得到注意力权

重矩阵 \bar{A} ：

$$\bar{A} = \text{softmax}\left(\frac{Q \cdot K^T}{\sqrt{d_K}}\right) \quad (7)$$

其中， softmax 函数将任意实数向量转化为概率分布，使得所有元素的值非负且总和为 1。

最终，通过将注意力权重矩阵 \bar{A} 与值矩阵 V 相乘，得到输出结果 O ：

$$O = \text{Attention}(Q, K, V) = \bar{A} \cdot V = \text{softmax}\left(\frac{Q \cdot K^T}{\sqrt{d_K}}\right) \cdot V \quad (8)$$

在本研究中，为了提高特征矩阵中关键特征的权重，引入通道自注意力机制。通道自注意力机制是在自注意力机制的基础上所提出的，与传统的自注意力机制不同的是，通道自注意力机制主要关注通道维度上的信息，通过计算各通道间的相关性，捕捉特征矩阵在不同通道上的依赖关系，从而提升模型的表现^[24]。

在通道自注意力机制下，假设输入矩阵 $X \in R^{C \times H \times W}$ ，其中 C 表示通道数， $H \times W$ 表示每个通道的空间尺寸，则查询矩阵 Q 、键矩阵 K 和值矩阵 V 的计算方法如下所示：

$$Q = X \otimes W_Q \quad (9)$$

$$K = X \otimes W_K \quad (10)$$

$$V = X \otimes W_V \quad (11)$$

其中， \otimes 表示卷积操作，此处采用 1×1 的卷积核进行计算。

在计算通道自注意力权重之前，需要将输入矩阵的尺寸重排为二维矩阵：

$$Q' = \text{reshape}(Q, (C, H \times W)) \quad (12)$$

$$K' = \text{reshape}(K, (C, H \times W)) \quad (13)$$

$$V' = \text{reshape}(V, (C, H \times W)) \quad (14)$$

其中，重排后的矩阵尺寸为 $(C, H \times W)$ 。

通道自注意力权重矩阵 \bar{A} 的计算公式为：

$$\bar{A} = \text{softmax}\left(\frac{Q' \cdot K'^T}{\sqrt{C}}\right) \quad (15)$$

则经过通道自注意力处理的矩阵 O 为：

$$O = \bar{A} \cdot V' = \text{softmax}\left(\frac{Q' \cdot K'^T}{\sqrt{C}}\right) \cdot V' \quad (16)$$

最后，将结果重排回原始尺寸，得到输出矩阵 O' 为：

$$O' = \text{reshape}(O, (C, H, W)) \quad (17)$$

通过通道自注意力机制，输入矩阵中不同通道的显著特征得到增强，从而使模型能够更充分地利用各通道的信息，进一步提升模型的性能。

2.2 特征权重自适应算法

在本研究中，为了进一步提升 MC-CNN 提取的特征的表现力和泛用性，引入了基于通道自注意力机制(ECA)的特征权重自适应模块。该模块通过自适应调节特征矩阵

的权重，以增强模型在不同工况下对输入信号的适应能力，同时提高整体计算效率。

特征权重自适应模块包括一个池化层、一个卷积层和一个激活函数。相比于全连接层，这种配置具有参数较少、计算开销低、结构简洁等优点，并且能够适应多种神经网络架构，从而有效提高模型的表示能力。模块的具体参数设置如下：


▲表 2 特征权重自适应模块结构

神经网络层	输出格式	参数量
输入层	128×77	0
转置层	77×128	0
池化层	77×1	0
转置层	1×77	0
卷积层	1×77	3
激活函数层	1×77	0
加权层	128×77	0
总参数量：3		

其中，池化层采用一维平均池化，负责对每个通道的特征参数进行压缩。卷积层使用一维卷积，卷积核尺寸为 3，用于计算通道自注意力权重。激活函数采用 Sigmoid 函数，将卷积得到的通道自注意力权重限制在 0 到 1 之间。最终，通过对原始特征矩阵与通道自注意力权重进行加权，得到经过自适应调整的特征矩阵，从而提高模型的整体性能和适应能力。

2.3 铣削颤振在线监测模型

综合多源信号输入的特征提取算法和特征权重自适应算法，本研究提出了一种铣削颤振在线监测模型。该模型的工作流程如下：首先，将多通道传感器信号输入到基于 MC-CNN 的特征提取算法中，以提取特征参数矩阵。其次，通过基于 ECA 的权重自适应算法对特征参数的权重进行动态调整，以获得优化的特征矩阵。最后，将优化后的特征矩阵输入到基于 CNN 的分类功能模块中，以实现铣削颤振的实时监测和分类。模型运行的流程如下图所示：



▲图 3 铣削颤振在线监测流程

按照各模块间输入输出矩阵尺寸的对应关系，将多通道并行特征提取模块（MC-CNN）、特征权重自适应调节模块（ECA）和分类功能模块串联，得到铣削在线监测模型整体网络结构和参数如下表所示：


▲表 3 铣削颤振在线监测网络结构

功能模块	神经网络层	输出格式	参数量
多通道并行特征提取模块 (MC-CNN)	输入层	21×20000	0
	卷积层 1	64×4996	21568
	激活函数层 1	64×4996	0
	池化层 1	64×1248	0
	卷积层 2	128×309	131200
	激活函数层 2	128×309	0
	池化层 2	128×77	0
特征权重自适应调节模块 (ECA)	转置层 1	77×128	0
	池化层 3	77×1	0
	转置层 2	1×77	0
	卷积层 3	1×77	3
	激活函数层 3	1×77	0
	加权层	128×77	0
分类功能模块 (CNN)	卷积层 4	128×77	49280
	激活函数层 4	128×77	0
	池化层 4	128×38	0
	卷积层 5	256×38	98560
	激活函数层 5	256×38	0
	池化层 5	256×19	0
	展平层	4864	0
	丢弃层 1	4864	0
	全连接层 1	512	2488840
	激活函数层 6	512	0
	丢弃层 2	512	0
	全连接层 2	3	1539
总参数量：2790990			

分类功能模块负责将经过多通道并行特征提取模块和特征矩阵权重自适应调节模块处理后的特征矩阵转化为分类结果。该模块包括两个卷积层、两个池化层、两个全连接层、三个激活函数层、一个展平层和两个丢弃层。

其中，两个卷积层采用一维卷积网络，卷积核尺寸为 3，用于从特征矩阵中提取高级特征。两个池化层进一步降低特征维度，从而提高计算效率并减少计算负担。展平层将二维特征矩阵展平成一维，以便于后续全连接层的处理。两个全连接层逐步降低特征维度，并最终将特征矩阵映射到三个输出参数上，这三个参数分别表示各类别的概率。最终，通过最大概率对应的类别确定分类结果。此外，两个丢弃层用于对特征矩阵进行正则化处理，通过随机丢弃网络中的部分神经元来增强模型的泛化能力，防止过拟合现象的发生。

综上所述,本研究提出了一种改进的铣削颤振在线监测模型。该模型综合了多通道并行卷积神经网络(MC-CNN)和基于通道自注意力机制(ECA)的特征权重自适应算法,优化了对多源信号的特征提取和处理能力。具体而言,模型首先通过MC-CNN对多通道传感器信号进行特征提取,然后利用ECA模块对特征矩阵进行权重自适应调节,最终通过分类功能模块将处理后的特征矩阵转换为铣削颤振的分类结果。整体设计提高了模型对不同工况下的适应性和计算效率,为铣削颤振监测提供了一种高效且精准的解决方案,整体模型结构图如下:




▲图4 改进的铣削颤振在线监测架构

3 实验与分析


3.1 实验装置搭建

为验证所提出模型的性能,本研究在卧式加工中心搭建了实验平台,并进行了铣削过程的数据采集,以构建实验数据集。实验采用了PT50精密卧式加工中心,该机床为五轴加工中心,配备了最大转速为12000 RPM、电主轴功率为40 kW的电主轴。

为了采集加工过程中的多源输入信号,本研究在机床上配置了整机振动信号实时采集系统。硬件方面,机床的X、Y、Z直线轴的轴承座、电机座及电主轴共配备了21个加速度传感器,这些传感器通过配套的高性能动态信号测试与分析系统将数据传输至采集终端。软件方面,采用东华测试数据采集软件,实现了最高50 kHz采样频率的振动信号实时采集。实验装置的配置如图5所示。



(a) 硬件连接示意图



(b) 实验装置图

▲图5 铣削颤振实验装置

实验中所使用的刀具为四齿盘铣刀,刀具直径为63mm,主偏角为 45° ,材料为硬质合金,工件材料为

HT200,其顶部可加工平面的尺寸为 $435.35\text{mm}\times 182\text{mm}$ 。

3.2 实验过程及数据集搭建


采用上述实验装置开展铣削颤振实验,实验中所使用的盘铣刀所允许的加工参数如下表所示,

▲表4 实验所用盘铣刀推荐切削参数

切削参数	主轴转速 (RPM)	进给速度 (mm/min)	切削深度 (mm)
允许范围	1000~1300	500~1000	0.5~2.5

据此设计实验过程中所采用的切削参数,每次铣削过程中,铣刀沿Z轴方向进给,完成一个面铣削过程。每个铣削过程可加工出5个台阶面。

在本实验中,将铣削过程中的稳定性划分为三个等级:稳定、轻微颤振和严重颤振。评估颤振等级时,本研究综合考虑了表面粗糙度和振纹情况。表面粗糙度指标 $Ra(\mu\text{m})$ 由Mitutoyo SJ210表面粗糙度仪测得。通过统计不同颤振等级下的表面粗糙度分布情况,设定了以下标准:当 $Ra < 1.6\mu\text{m}$ 且工件表面无明显振纹时,铣削过程稳定;当 $1.6\mu\text{m} \leq Ra < 2.0\mu\text{m}$ 且工件表面开始出现振纹时,铣削过程发生轻微颤振;当 $Ra > 2.0\mu\text{m}$ 且工件表面出现明显振纹时,铣削过程发生严重颤振。不同颤振等级下的表面粗糙度和振纹情况如图所示,



▲图6 不同颤振程度对应的表面粗糙度和振纹情况

实验过程中,每个面铣削过程中采用相同的主轴转速和进给速度,但切削深度有所不同。铣削完成后,对铣削表面进行粗糙度测量,并观察振纹情况。每道次测量三次以取平均值,从而综合判断铣削过程的颤振等级。本实验共进行了80组切削参数组合的铣削测试,具体的切削参数如下所示:

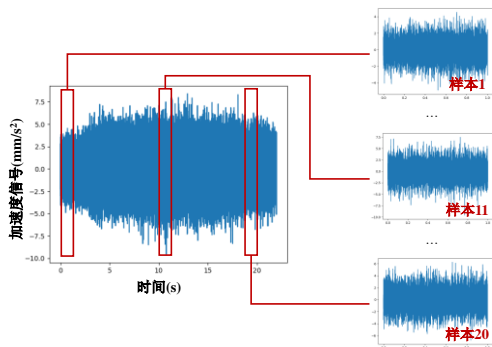
▲表 5 实验所用切削参数

实验 次序	主轴转速 (RPM)	进给速度 (mm/min)	切削深度(mm)				
			1道次	2道次	3道次	4道次	5道次
1	1000	500	0.5	0.7	0.9	1.1	1.3
2	1000	500	2.3	2.1	1.9	1.7	1.5
3	1000	1000	0.5	0.7	0.9	1.1	1.3
4	1100	500	2.5	2	1.5	1	0.5
5	1100	500	0.5	0.7	0.9	1.1	1.3
6	1100	500	2.3	2.1	1.9	1.7	1.5
7	1100	1000	0.5	0.7	0.9	1.1	1.3
8	1100	1000	2.3	2.1	1.9	1.7	1.5
9	1200	500	0.5	1	1.5	2	2.5
10	1200	500	0.5	0.7	0.9	1.1	1.3
11	1200	500	2.3	2.1	1.9	1.7	1.5
12	1300	500	2.5	2	1.5	1	0.5
13	1300	500	0.5	0.7	0.9	1.1	1.3
14	1300	500	2.3	2.1	1.9	1.7	1.5
15	1300	1000	0.5	0.7	0.9	1.1	1.3
16	1300	1000	2.3	2.1	1.9	1.7	1.5

采集铣削过程中机床振动信号，在机床的 X、Y、Z 直线轴的电机座、轴承座和电主轴均安装了振动传感器，共 21 个。通过东华测试采集终端同时采集各通道的传感器数据，设置采样频率为 20000 Hz。将采集到的传感器数据导出，并与实验后测得的颤振等级进行一一对应，从而搭建原始数据集。

3.3 实验数据处理

为了构建训练集和测试集，本研究设置了长度为 20,000 的滑动窗口，从加工开始时刻沿各传感器信号移动，步长为 20,000，直至加工结束时停止移动。滑动窗口对原始数据进行切割，生成等长度的加工数据，用于后续模型的测试，如下图所示。最终获得了 1,485 组样本，其中包括 286 组稳定样本、462 组轻微颤振样本和 737 组严重颤振样本。



▲图 7 样本数据切割


为了提高模型的泛化能力，对切割处理后的数据集应

用了数据增强技术，包括翻转和 SamplePairing 两种方法。由于铣削加工过程中的振动信号在正负方向上具有对称性，沿时间轴翻转振动信号可以生成新的样本。SamplePairing 是图像识别领域常用的数据增强技术，指从同类型样本中随机选择两个不同的样本，将它们逐点相加并取平均值以生成新的样本。通过 SamplePairing 方法，可以有效增加数据的多样性，使模型在训练过程中学习到更多信号变体，从而提升泛化能力。设置每个类别 SamplePairing 生成的样本组数上限为 4,000，数据增强后的总样本数为 14,970，其中稳定样本 4,572 组，轻微颤振样本 4,924 组，严重颤振样本 5,474 组。最终，将总数据集的 70%用于训练集，30%用于测试集。

3.4 实验结果及分析

在实验中，搭建了 2.3 节的神经网络模型。模型的整体结构和参数设置如表 3 所示。模型的输入参数包括：通道数为 21，单通道数据长度为 20,000，分类数为 3。模型训练过程中，使用了批量大小为 32 的训练数据，优化算法选择了 Adam 优化器，学习率设定为 0.0001，并且设置了权重衰减系数为 0.00001，以防止模型过拟合。模型共训练了 1,000 轮次，损失函数采用了交叉熵函数。

为验证本文提出的多通道并行特征提取模块（MC-CNN）和特征权重自适应调节模块（ECA）的有效性，开展了消融实验。实验通过分别测试以下几种网络配置的性能来进行对比：同时包含 ECA 和 MC-CNN 模块的网络、不包含 ECA 模块的网络、不包含 MC-CNN 模块的网络、不包含 ECA 和 MC-CNN 模块的网络。所有网络均使用相同的训练集和测试集进行评估，以确保公平对比。在消融实验中，得到的准确度曲线如下图所示：



▲图 8 消融实验准确度曲线

观察准确度曲线可知，采用多通道并行特征提取模块（MC-CNN）与分类功能模块（CNN）相比于仅采用分类功能模块（CNN）的基准模型，不仅提升了 0.87% 的分类准确度，还能在 165 次迭代内达到稳定状态。此外，引入特征权重自适应调节模块（ECA）与 MC-CNN 时，模型的识别准确率进一步提高至 99.62%，且收敛速度显著提升，仅需 97 次迭代即可达到稳定状态。具体各模型收敛后分类准确率和收敛所需迭代次数如下表所示，

▲表 6 消融实验结果

模型	分类准确率	收敛所需迭代次数
MC-CNN+ECA+CNN	99.62%	97
MC-CNN+CNN	99.53%	165
ECA+CNN	98.68%	895
CNN	98.66%	920

从表中可以看出，引入 MC-CNN 和 ECA 模块的组合模型在准确率和收敛速度上均表现优异，验证了这两种模块对提升模型性能的显著作用。

为验证本文所提出的 MC-CNN+ECA+CNN 完整模型的性能，本研究将其与其他常用分类模型进行对比。对比模型包括基于 PyTorch 库搭建的长短期记忆网络 (LSTM) 模型和 Transformer 模型，以及基于 Scikit-Learn 库搭建的支持向量机 (SVM) 模型、逻辑回归 (Logistic Regression) 模型、随机森林 (Random Forest) 模型、K 近邻 (K-Nearest) 模型和多层感知机 (MLP) 模型。

由于部分对比模型无法直接处理时域信号，因此在将信号输入这些模型之前，需要先提取时域和频域特征，共计 24 个特征^[16]。其中，时域特征包括偏度、峭度、峰值因子和波形因子等，而频域特征则涵盖信号的均值和均方根等。此外，为了全面评估模型性能，还对不同模型达到最大准确率所需的时间进行了对比，包括特征提取的时间。对比结果如表所示：

▲表 7 不同模型在实验数据集下的结果对比

模型	分类准确率	训练所需时间
LSTM	97.42%	3476.51s
Transformer	91.04%	4882.46s
SVM	94.22%	1635.39s
Logistic Regression	92.71%	1569.10s
Random Forest	97.28%	1606.85s
K-Nearest	94.05%	1591.60s
MLP	97.97%	1597.99s
MC-CNN+ECA+CNN	99.62%	1078.60s

在实验数据集上，本文提出的 MC-CNN+ECA+CNN 模型表现出色，其分类准确率高达 99.62%，且达到这一准确率所需的时间为 1078.60 秒，准确度提升了 1.65%，训练时间缩短了 31.26%。这一性能优势得益于模型中的两个关键模块：MC-CNN 和 ECA。MC-CNN 通过多通道并行处理有效提取了时域信号中的复杂特征，而 ECA 则通过自适应调节特征矩阵的权重，进一步提升了模型的特征表达能力和泛化性能。这些特点使得 MC-CNN+ECA+CNN 模型在保证高分类准确率的同时，也具备了较高的计算效率。

综上所述，MC-CNN+ECA+CNN 模型在处理多源输入信号时，凭借其出色的特征提取和权重自适应调节能力，不仅实现了最高的分类准确率，还优化了模型的计算效率，展现了在实际应用中的优越性能。

4 结论

本文提出了一种基于多源信号融合和卷积神经网络的铣削颤振在线监测方法。相比于传统铣削颤振监测方法：

(1) 引入了多通道并行卷积神经网络 (MC-CNN)，通过利用卷积神经网络的局部感受和全局共享权重的特性。本文所提方法显著提高了模型的泛化能力。

(2) 提出了基于通道自注意力机制 (ECA) 的特征权重自适应调整方法。该方法通过引入通道自注意力机制，动态调整特征矩阵中的权重，增强了模型对关键特征的识别能力，并提高了计算效率。

在卧式加工中心进行铣削实验，复现了稳定加工、轻微颤振和严重颤振三种加工状态。实验结果表明，所提出的模型相较于现有的颤振监测模型，在分类准确率上显著提升，同时计算效率得到提高，训练所需时间显著减少。

参考文献

- [1] YUE Caixu, GAO Haining, LIU Xianli, et al. A review of chatter vibration research in milling[J]. Chinese Journal of Aeronautics, 2019, 32(2): 215-242.
- [2] 李益文, 邓朝晖, 刘涛. 切削加工过程中颤振在线监测研究综述[J]. 航空学报, 2023, 44(11): 6-23.
LI Yiwen, DENG Zhaohui, LIU Tao. Review on on-line monitoring of chatter in cutting process[J]. Acta Aeronautica et Astronautica Sinica, 2023, 44(11): 6-23.
- [3] 王志学, 刘献礼, 李茂月, 等. 切削加工颤振智能监控技术[J]. 机械工程学报, 2020, 56(24): 1-23.
WANG Zhixue, LIU Xianli, LI Maoyue, et al. Intelligent Monitoring and Control Technology of Cutting Chatter. Journal of Mechanical Engineering, 2020, 56(24): 1-23.
- [4] 王鑫. 面向薄壁筒切削加工的多频颤振监测方法及实验研究[D]. 太原: 太原理工大学, 2023.
WANG Xin. Multi-frequency chatter monitoring method and experimental research for thin-walled cylinder machining[D]. Taiyuan: Taiyuan University of Technology, 2023.
- [5] ZHANG Pengfei, GAO Dong, LU Yong, et al. Online chatter detection in milling process based on fast iterative VMD and energy ratio difference[J]. Measurement, 2022, 194: 111060.
- [6] 崔传祯. 机器人铣削在线颤振识别方法及变进给速度颤振抑制方法研究[D]. 济南: 山东大学, 2023.
CUI Chuanyi. Research on online chatter identification method and variable feed rate chatter suppression method for robot milling[D]. Jinan: Shandong University, 2023.
- [7] LI Kai, HE Songping, LUO Bo, et al. Online chatter detection in milling process based on VMD and multiscale entropy[J]. The International Journal of Advanced Manufacturing Technology, 2019, 105: 5009-5022.
- [8] 赵明伟. 薄壁件铣削稳定性及颤振状态在线监测研究[D]. 哈尔滨: 哈尔滨理工大学, 2023.
ZHAO Mingwei. Research on milling stability and on-line chatter monitoring of thin-walled parts[D]. Harbin: Harbin University of Science and Technology, 2023.
- [9] WANG WeiKang, WAN Min, ZHANG WeiHong, et al. Chatter detection methods in the machining processes: A review[J]. Journal of Manufacturing Processes, 2022, 77: 240-259.
- [10] FU Yang, ZHANG Yun, ZHOU Huamin, et al. Timely online chatter detection in end milling process[J]. Mechanical Systems and Signal Processing, 2016, 75: 668-688.
- [11] TANSEL I N, LI M, DEMETGUL M, et al. Detecting chatter and estimating wear from the torque of end milling signals by using Index Based Reasoner (IBR) [J]. The International Journal of Advanced Manufacturing Technology, 2012, 58: 109-118.
- [12] LI Kai, HE Songping, LI Bin, et al. A novel online chatter detection method in milling process based on multiscale entropy and gradient tree boosting[J]. Mechanical Systems and Signal Processing, 2020, 135: 106385.
- [13] LAMRAOUI M, BADAoui M EI, GUILLET F. Chatter detection in CNC milling processes based on Wiener-SVM approach and using only motor current signals[C]. Vibration Engineering and Technology of Machinery: Proceedings of VETOMAC X 2014. Manchester, UK: Springer International Publishing, 2015: 567-578.
- [14] SHI Fei, CAO Hongrui, ZHANG Xingwu, et al. A reinforced k-nearest neighbors method with application to chatter identification in high-speed milling[J]. IEEE Transactions on Industrial Electronics, 2020, 67(12): 10844-10855.
- [15] LEI Yaguo, HE Zhengjia, ZI Yanyang, et al. Fault diagnosis of rotating machinery based on multiple ANFIS combination with Gas[J]. Mechanical systems and signal processing, 2007, 21(5): 2280-2294.
- [16] LAMRAOUI M, BARAKAT M, THOMAS M, et al. Chatter detection in milling machines by neural network classification and feature selection[J]. Journal of Vibration and Control, 2015, 21(7): 1251-1266.
- [17] JIA Guangfei, WU Bo, HU Youmin, et al. A synthetic criterion for early recognition of cutting chatter[J]. Science China Technological Sciences, 2013, 56: 2870-2876.
- [18] LIU Chang, XU Weiwei, GAO Lei. Identification of milling chatter based on a novel frequency-domain search algorithm[J]. The International Journal of Advanced Manufacturing Technology, 2020, 109(9): 2393-2407.
- [19] CHEN Yun, LI Huaizhong, JING Xiubing, et al. Intelligent chatter detection using image features and support vector machine[J]. The International Journal of Advanced Manufacturing Technology, 2019, 102: 1433-1442.
- [20] NAVARRODEVIA J H, CHEN Yun, DAO D, et al. Chatter detection in milling processes—a review on signal processing and condition classification[J]. The International Journal of Advanced Manufacturing Technology, 2023, 125(9): 3943-3980.
- [21] LIU Jie, WU Bo, WANG Yan, et al. An integrated condition-monitoring method for a milling process using reduced decomposition features[J]. Measurement Science and Technology, 2017, 28(8): 085101.
- [22] FU Yang, ZHANG Yun, GAO Huang, et al. Automatic feature constructing from vibration signals for machining state monitoring[J]. Journal of Intelligent Manufacturing, 2019, 30: 995-1008.
- [23] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [24] WANG Qilong, WU Banggu, ZHU Pengfei, et al. ECA-Net: Efficient channel attention for deep convolutional neural networks[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. Online: IEEE, 2020: 11534-11542.

作者简介: 金一涵(2000—), 男, 硕士研究生, 主要研究方向为加工过程智能维护方法研究。